

Raport ze wstępnych badań projektu zespołowego Big Data

Propozycja trasy na podstawie otwartych danych nawigacyjnych dla miasta stołecznego Warszawy

Zespół 12:

Michał Zalewski

Jakub Próchnicki

Jan Machowski

Maciej Kurzydłowski

Jan Domański

Warszawa, 21 maja 2026

Spis treści

1	Wstęp	3
2	Infrastruktura oraz potok przetwarzania danych	3
2.1	Przedstawienie infrastruktury	3
2.2	Potok danych	4
2.2.1	Źródła danych	4
2.2.2	Struktura surowych danych - wykresy	8
2.2.3	Pobór danych - Kafka	8
2.2.4	Czyszczenie i transformacja danych - Apache Spark, OSMnx	9
2.2.5	Zapis danych	10
2.2.6	Diagram potoku danych	10
3	Instalacja, konfiguracja oraz wykonanie projektu	11
3.1	Instalacja i zbudowanie projektu	11
3.2	Pobór danych (ingestion)	11
3.3	Konfiguracja skryptów analizy	12
3.4	Dane wyjściowe	13
4	Wstępna analiza problemu	13
4.1	Cel i metodyka	13
4.2	Wyniki wstępne	13
4.3	Wnioski	14
5	Dalsze kierunki badania	14
6	Podsumowanie	15

1 Wstęp

Niniejszy raport jest podsumowaniem kontynuowanych działań dążących do opracowania modelu propozycji trasy przejazdu w Warszawie, na podstawie dostępnych jawnie danych nawigacyjnych. Główny cel tego dokumentu to przedstawienie infrastruktury stworzonej w ramach projektu, potoku przetwarzania danych oraz efektu działania systemu w porównaniu z istniejącymi rozwiązaniami. Opisana zostanie również wstępna analiza wyżej wymienionego problemu oraz wnioski wyciągnięte z tej analizy.

W poprzednim dokumencie został zawarty przegląd tematyki, wstępna propozycja źródeł i narzędzi wykorzystanych do wykonania projektu oraz problemów i ograniczeń związanych z wybranymi danymi.

W celu przypomnienia - zaproponowana została reprezentacja miasta w postaci grafu skierowanego, gdzie wierzchołki są przecięciami (skrzyżowaniami) lub zakończeniami dróg, a krawędzie są rzeczywistymi odcinkami dróg. Każda krawędź posiada odpowiedni zestaw atrybutów:

- długość;
- typ drogi;
- liczba pasów;
- natężenie ruchu.

Propozycja ta została wykorzystana do stworzenia wstępnego rozwiązania, opisanego w poprzednim raporcie. Rozwiązanie to zostało przedstawione poniżej.

Aby zachować pełnię oraz spójność dokumentu, niektóre informacje zostały powielone oraz zaktualizowane o najnowsze zmiany w projekcie (przykładowo: opisy źródeł danych, które znajdowały się w poprzedniej wersji projektu). Dodatkowo zostaną zawarte nowe informacje dotyczące aspektów programu, które zostały dodane. Dzięki temu, dokument ten jest spójnym opisem całego projektu.

2 Infrastruktura oraz potok przetwarzania danych

2.1 Przedstawienie infrastruktury

Projekt został przygotowany jako środowisko skonteneryzowane w technologii *Docker*. Projekt można uruchomić za pomocą komendy **Docker Compose**. Pozwala to na odtworzenie środowiska na różnych urządzeniach bez potrzeby ręcznego instalowania zależności systemowych lub bibliotek. W kontenerze **opennavigation** znajdują się wszystkie narzędzia potrzebne do pobierania, przetwarzania i analizy danych.

W ramach projektu wykorzystano następujący stos technologiczny:

1. **Python** - główny język implementacji;
2. **OSMnx** i **NetworkX** - biblioteki Python'owe wykorzystywane do pracy z grafem drogowym Warszawy;
3. **Pandas** - biblioteka wykorzystana do przetwarzania danych tabelarycznych, agregacji wyników oraz zapisu plików wynikowych;
4. **Apache Kafka** - system wymiany danych umożliwiający przesyłanie danych w różnych etapach potoku przetwarzania danych;
5. **Apache Spark** - rozwiązanie wykorzystywane do przetwarzania danych strumieniowych oraz transformację surowych danych w dane gotowe do analizy.

W projekcie nie wykorzystano czystego Hadoopa, co jest zgodne z przyjętym zakresem projektu - technologia ta była traktowana jako opcjonalne narzędzie. Zamiast tego, dane są przetwarzane lokalnie a wyniki są zapisywane w strukturze katalogów projektu.

Struktura danych w projekcie podzielona jest na trzy katalogi:

- **data/raw** - katalog przechowujący dane surowe, m.in. raporty XLSX/PDF zaczerpnięte ze źródeł zewnętrznych;

- **data/processed** - katalog przechowujący dane oczyszczone oraz zagregowane, wykorzystywane do zadania analizy tras;
- **data/results** - katalog przechowujący wyniki analiz - m.in. porównanie tras.

W obecnej wersji projektu, możliwe jest uruchomienie pełnej analizy trasy w następujących krokach:

1. Pobranie danych źródłowych (raporty XLSX/PDF z zewnętrznych źródeł);
2. Przetworzenie danych (czyszczenie, transformacja, agregacja);
3. Wyznaczenie trasy na podstawie przetworzonych danych;
4. Porównanie różnych wariantów trasy według odpowiednich funkcji kosztu.

2.2 Potok danych

Potok danych został przygotowany w sposób, który umożliwia łączenie różnych źródeł danych w jeden, spójny model kosztu przejazdu.

Podstawą analizy jest graf drogowy Warszawy, stworzony na podstawie danych pobranych z **OpenStreetMap** za pomocą biblioteki **OSMnx**. Pierwotny, pobrany graf jest wzbogacany o następujące dane:

- **ZDM** - dane dotyczące natężenia ruchu oraz średnich prędkości pojazdów. Dane te są punktowe, więc są wykorzystywane do korekty kosztu przejazdu tylko dla tych krawędzi, dla których są dostępne. W ramach poprawy modelu, można wykorzystać alternatywne źródło strumieniowych danych **TomTom** opisane poniżej;
- **Dane pogodowe** - dane dotyczące warunków pogodowych, które wpływają na czas przejazdu - deszcz, mgła etc.

Potok obejmuje następujące etapy:

- Pobór danych;
- Czyszczenie i transformację danych;
- Agregację danych do postaci użytecznej w analizie tras;
- Zapis wyników pośrednich i końcowych.

Szczegółowy opis poszczególnych etapów potoku przedstawiono w kolejnych podpunktach.

2.2.1 Źródła danych

Źródła danych obejmują zarówno statyczny opis sieci drogowej, jak i dane zmienne w czasie. W projekcie wykorzystano następujące źródła:

- **OpenStreetMap / Overpass API** - źródło zawierające geometrię sieci drogowej Warszawy oraz atrybuty odcinków (np. *highway*, *maxspeed*, *lanes*, *oneway*). Te dane stanowią podstawę do budowy grafu ulic oraz wyznaczenia bazowych czasów przejazdu. Przykład zapytania Overpass API używanego w projekcie (wybór dróg głównych dla Warszawy):

```
[out:json][timeout:120];
area["name"="Warszawa"]->.a;
(
  way["highway"~"^(primary|secondary|tertiary)$"](.a);
);
(._;>);
out body;
```

Przykładowy fragment odpowiedzi (rzeczywisty wynik, ograniczony do pojedynczego odcinka dla czytelności):

```
{
  "elements": [
    {
      "type": "way",
      "id": 4307329,
      "nodes": [
        2448759046,
        7093785352,
        2452307268,
        1439574696
      ],
      "tags": {
        "cycleway:both": "no",
        "highway": "tertiary",
        "junction": "roundabout",
        "lane_markings": "no",
        "lit": "yes",
        "maxspeed": "50",
        "name": "Rondo Feliksa Stamma",
        "name:etymology:wikidata": "Q5441838",
        "sidewalk:left": "no",
        "sidewalk:right": "separate",
        "source:maxspeed": "PL:urban",
        "surface": "asphalt",
        "wikidata": "Q113528575"
      }
    }
  ]
}
```

- **ZDM Warszawa (APR)** - źródło zawierające punktowe pomiary natężenia ruchu na wybranych odcinkach. Dane są pobierane z panelu *Analiza ruchu na drogach online* (<https://zdm.waw.pl/dzialania/badania-i-analizy/analiza-ruchu-na-drogach/analiza-ruchu-na-drogach>) w postaci raportu XLSX. Pobieranie jest zautomatyzowane skryptem `zdm_online_traffic_loader.py`, który steruje interfejsem WWW (Playwright) i zapisuje raport do pliku.

Tabela 1 przedstawia uproszczony format rekordu APR, który trafia do potoku danych po wczytaniu raportu XLSX.

Tabela 1: Format danych ZDM APR (po wczytaniu do potoku)

Pole	Opis
source	Identyfikator źródła (np. <i>zdm_apr_real</i>).
station_id	Id punktu pomiarowego ZDM.
station_name	Nazwa punktu pomiarowego (np. ulica/sekcja).
road_name	Nazwa ulicy.
section	Opis odcinka (np. między skrzyżowaniami).
direction	Kierunek pomiaru.
lat, lon	Współrzędne geograficzne punktu.
measurement_time	Czas pomiaru w formacie <i>YYYY-MM-DD HH:00:00</i> .
period_minutes	Okno czasowe pomiaru (zwykle 60).
vehicle_count	Liczba pojazdów w danym oknie.
avg_speed_kmh	Brak w APR (pole puste).
_metadata	Metadane techniczne: czas wczytania, plik źródłowy, arkusz.

- **Raporty prędkości ZDM (PDF)** - źródło zawierające cykliczne raporty z uśrednionymi prędkościami, publikowane na pulpicie ZDM (<https://zdm-warszawa.maps.arcgis.com/apps/dashboards/20bfffc9bae544b5a1cdfaad7be38c40>). Pobieranie plików jest zautomatyzowane skryptem `zdm_speed_report_downloader.py`. Następnie skrypt `zdm_speed_pdf_parser.py` przetwarza pliki PDF do formatu CSV (`zdm_speed_measurements.csv`).

Tabela 2 pokazuje uproszczony format rekordu z raportów prędkości.

Tabela 2: Format danych ZDM – raporty prędkości (po parsowaniu PDF)

Pole	Opis
source	Identyfikator źródła (np. <i>zdm_speed.pdf</i>).
source_file	Nazwa pliku PDF, z którego pochodzi rekord.
station_id	Id punktu pomiarowego ZDM.
station_name	Nazwa punktu (np. ulica/sekcja).
road_name	Nazwa ulicy.
direction	Kierunek pomiaru.
lat, lon	Współrzędne geograficzne punktu.
measurement_date	Data raportu (YYYY-MM-DD).
measurement_time	Znaczniki czasu (domyślnie 00:00:00).
period_minutes	Okres uśrednienia (1440 minut).
day_of_week	Dzień tygodnia z raportu.
vehicle_count	Liczba pojazdów (jeśli dostępna).
avg_speed_kmh	Średnia prędkość dla kierunku/dnia.
avg_speed_day_kmh	Średnia prędkość w dzień.
avg_speed_night_kmh	Średnia prędkość w nocy.
avg_speed_light_kmh	Prędkość dla pojazdów lekkich.
avg_speed_heavy_kmh	Prędkość dla pojazdów ciężkich.
vmax_kmh, v85_kmh	Prędkości Vmax i V85 (jeśli dostępne).
vdop_raw	Dopuszczalna prędkość (surowy zapis z PDF).

- **Open-Meteo** - źródło danych pogodowych w podziale godzinowym - opady, wiatr, widoczność, temperatura. Pobieranie z API realizuje skrypt `weather_loader.py`, który zapisuje pełny plik JSON do tematu Kafki (temat *warszawa-raw-weather*). Dane te stanowią kontekst do dodatkowej korekty kosztu.

Przykład zapytania API (parametry używane w projekcie):

```
https://api.open-meteo.com/v1/forecast?
latitude=52.2297&
longitude=21.0122&
hourly=temperature_2m,precipitation,rain,snowfall,wind_speed_10m,
visibility,weather_code&
forecast_days=1&
timezone=Europe/Warsaw
```

Przykładowy fragment odpowiedzi (rzeczywisty wynik, skrócony do kilku godzin):

```
{
  "latitude": 52.23009,
  "longitude": 21.017075,
  "timezone": "Europe/Warsaw",
  "hourly": {
    "time": [
      "2026-05-22T00:00",
      "2026-05-22T01:00",
      "2026-05-22T02:00"
    ],
    "temperature_2m": [16.9, 15.9, 14.9],
    "precipitation": [0.0, 0.0, 0.0],
    "wind_speed_10m": [11.2, 8.6, 6.1],
    "weather_code": [3, 0, 3]
  }
}
```

- **TomTom** - źródło danych strumieniowych, z którego pozyskiwane są informacje dotyczące szacowanych, aktualnych prędkości oraz czasów przejazdu na drogach najbliższych do wybranych, wysłanych przez użytkownika API współrzędnych - wszystkie te dane są, oczywiście, obarczone współczynnikiem pewności *confidence*.


Wykorzystanie tych danych realizuje skrypt `tomtom_traffic_loader.py` zapisujący dane w Kafce pod tematem *warszawa-raw-traffic*. Dzięki tym danym, które po transformacji za pomocą `tomtom_edge_mapping` są transformowane do formatu obsługiwanego przez istniejący plik `zdm_traffic_aggregation.py`, stanowią dodatkową podstawę do analizy korków na drogach Warszawy. *Dane te są przekształcone i wykorzystywane w analogiczny sposób co dane ZDM, więc w sekcji 2.2.4 transformacje tych danych nie będą dodatkowo opisywane.* W ramach zyskania dostępu do danych TomTom potrzebny jest klucz API. Można go zdobyć bezkosztownie na stronie *my.tomtom.com*. Po uzyskaniu należy owy klucz wstawić do pliku `.env`.

W projekcie, w celu pobrania danych wykorzystywane jest zapytanie GET. Przykład wykorzystania API TomTom oraz uzyskanych od niego informacji znajduje się poniżej:

```
{
  https://api.tomtom.com/traffic/services/4/flowSegmentData/absolute/
  10/json,
  params={
    "key": TOMTOM_API_KEY,
    "point": f"{52.218662},{21.017080}",
    "unit": "KMPH",
    "style": "relative",
  },
  timeout=30,
}


...

{
  "flowSegmentData": {
    "-xmlns": "http://lbs.tomtom.com/services",
    "-version": "traffic-service 2.0.004",
    "frc": "FRC2",
    "currentSpeed": 34,
    "freeFlowSpeed": 50,
    "currentTravelTime": 43,
    "freeFlowTravelTime": 30,
    "confidence": 0.71,
    "roadClosure": true,
    "coordinates": {
      "coordinate": [
        {
          "latitude": 52.218662,
          "longitude": 21.017082
        }
      ]
    }
  }
}
```



Rysunek 1: Średnia entropia, rozumiana w sensie teorii informacji, dla poszczególnych typów plików źródłowych (nieprzetworzonych)

2.2.2 Struktura surowych danych - wykresy



Rysunek 2: Średni rozmiar pliku źródłowego według typu pliku źródłowego (nieprzetworzonego)

Pliki typu pdf są najmniej ustrukturyzowanym źródłem danych w naszym projekcie, co potwierdza wysoka entropia zawartości tych plików. Największy udział w danych źródłowych pod względem rozmiaru mają pliki w formacie JSON, które jednocześnie charakteryzuje najmniejsza entropia, co może oznaczać najwyższy poziom ustrukturyzowania spośród wszystkich wykorzystywanych typów plików.

2.2.3 Pobór danych - Kafka

Pobór danych realizowany jest przez skrypty wczytujące, które zapisują dane wejściowe jako wiadomości JSON w tematach Apache Kafka. Poniżej znajduje się zestawienie przyjmowanych przez Kafkę danych z podziałem na poszczególne tematy oraz dalszy kierunek przekazywania danych:

- **warszawa-raw-streets** –
 - Źródło: Overpass API;
 - Producent: `overpass_raw_street_loader.py`;
 - Konsument: `overpass_transformations.py`;
 - Zapis do katalogu: `/app/data/processed/osm_ways`

– Publikacja do tematu: *warszawa-processed-edges*.

- **warszawa-raw-traffic**

- Źródło: ZDM / TomTom;
- Producent: `zdm_traffic_loader.py` lub `traffic_loader.py`;
- Konsument: `traffic_transformations.py`;
- Zapis do katalogu: `/app/data/processed/traffic_measurements`;
- Późniejsza agregacja: `zdm_traffic_aggregation.py`, `/app/data/processed/zdm_traffic_by_road.csv`.

- **warszawa-raw-weather**

- Źródło: Open-Meteo;
- Producent: `weather_loader.py`;
- Konsument: `weather_transformations.py`;
- Zapis do katalogu: `/app/data/processed/weather_observations`.

- **warszawa-processed-edges** – ujednolicone krawędzie grafu po transformacji OSM; temat wyjściowy z `overpass_transformations.py`, możliwy do dalszego wykorzystania analitycznego.

W obecnej wersji zasilanie odbywa się wsadowo (mikro-batch), jednak potok działa w trybie strumieniowym po stronie Apache Spark. Kafka pełni rolę bufora i kolejki zdarzeń, co zwiększa powtarzalność obliczeń i pozwala na odtwarzanie danych od wybranego offsetu.

2.2.4 Czyszczenie i transformacja danych - Apache Spark, OSMnx

W ramach tego etapu, dane debrane w zasobach Kafki są przekształcane do postaci, która zostanie wykorzystana w późniejszym etapie - analizie tras.

Dane **ZDM APR** są pobierane do Apache Kafka w surowej postaci, a następnie przetwarzane z pomocą Apache Spark. Skonfigurowane rozwiązanie Spark odczytuje komunikaty z tematu **warszawa-raw-traffic**, które są w formacie JSON, po czym analizuje oraz przekształca je do postaci tabelarycznej. W ramach tego procesu, program ujednolica nazwy kolumn, konwertuje czas pomiaru do formatu daty i czasu oraz przelicza liczbę pojazdów w postać natężenia ruchu - $natezenie = \frac{l.pojazdow}{h}$.

Na tym etapie wyznaczany jest również współczynnik **traffic_factor**, który jest później wykorzystywany jako **kara kosztu przejazdu** dla ulic, które mają dostępne pomiary natężenia ruchu.

W trakcie transformacji dochodzi do agregacji danych **ZDM APR** po ulicach - z wielu rekordów godzinowych wybierane są maksymalne/średnie wartości **traffic_factor**, liczby pomiarów oraz zakresy dat. Wynikiem tych operacji jest plik **zdm_traffic_by_road.csv**, pozwalający na uruchomienie analizy tras bez ponownej potrzeby przetwarzania dużych danych wejściowych.

Proces czyszczenia i transformacji dla danych o dozwolonych prędkościach z *ZDM* (w formie PDF) jest bardziej złożony. Dane są przetwarzane osobnym analizatorem składniowym. Pobierane są zawartości plików PDF a następnie wydobywane są z nich kluczowe informacje, takie jak:

- Identyfikator punktu pomiarowego;
- Nazwa ulicy;
- Lokalizacja (współrzędne geograficzne);
- Data pomiaru;
- Średnia prędkość **avg_speed_kmh**.

W przypadku, w którym dla konkretnej ulicy istnieje wiele pomiarów średniej prędkości w różnych odstępach czasowych, na tych danych również wykonywana jest agregacja. Jeżeli informacja dotycząca liczby pojazdów jest dostępna, wyznaczana jest średnia ważona, gdzie waga jest liczbą pojazdów. W przeciwnym razie, wyznaczana jest średnia arytmetyczna.

Wykorzystując bibliotekę **OSMnx**, system tworzy strukturę sieci drogowej Warszawy. Dla danego obszaru miasta pobierany jest graf drogowy o typie *network_type = 'drive'*¹, który odpowiada ulicom przeznaczonym dla pojazdów. Dla tych ulic, bazowe prędkości/czasu przejazdu dla krawędzi są wyznaczone automatycznie, po czym są wzbogacane o następujące atrybuty:

- **traffic_factor** - korekta kosztu przejazdu na podstawie ZDM APR - danych o natężeniu ruchu;
- **speed_factor** - korekta na podstawie prędkości ruchu z raportów ZDM;
- **weather_factor** - korekta na podstawie danych o pogodzie;
- **traffic_speed_factor** - ostateczna korekta wynikająca z danych ruchu i prędkości - jest ona wyznaczana jako maksimum z wartości **traffic_factor** i **speed_factor**;
- **cost_time_s** - końcowa waga krawędzi w grafie, będąca wartością czasu w sekundach, uwzględniająca bazowy czas przejazdu i dostępne korekty.

Dodatkową, istotną operacją wykonywaną podczas transformacji danych jest normalizacja nazwy ulic. Dane ZDM są dopasowywane do poszczególnych krawędzi grafu względem nazwy ulic, a OpenStreetMap oraz ZDM często posiadają różne formy zapisu konkretnych nazw ulic, przykładowo: Al. lub Aleje, Ul. lub Ulica, ... Transformator danych stosuje uproszczone, ujednolicone nazwy ulic - w celu osiągnięcia tego efektu usuwane są wybrane skróty.

Na etapie transformacji normalizowane są też nazwy ulic, bowiem ZDM oraz OpenStreetMap mogą mieć różne formy zapisu nazw konkretnych ulic, np. Al. i Aleje. Potok stosuje uproszczone ujednolicanie nazw i usuwanie wybranych skrótów. Jest to istotne, ponieważ dane ZDM są głównie dopasowywane do krawędzi po nazwach ulic, co na późniejszym etapie zostanie zastąpione dopasowaniem przestrzennym.


2.2.5 Zapis danych

Po oczyszczeniu, przekształceniu i wzbogaceniu danych o dodatkowe atrybuty odbywa się ich zapis do poszczególnych katalogów w projekcie. W tej kwestii zastosowano następujący podział:

- Dane surowe, takie jak raporty XLSX/PDF, są zapisywane w katalogu **data/raw**;
- Dane przetworzone, takie jak pomiary natężenia ruchu czy dane pogodowe, są zapisywane w katalogu **data/processed**. Format zapisu dla danych tabelarycznych to *Parquet*;
- Wyniki analiz są zapisywane w katalogu **data/results**.

2.2.6 Diagram potoku danych

Potok danych można całokształtnie przedstawić na następującym diagramie:



Rysunek 3: Diagram potoku danych.

¹Typy grafów są jednoznaczne z przeznaczeniem danej drogi, tj. ulica, trasa rowerowa, chodnik etc. Listę dostępnych typów można znaleźć w dokumentacji OSMnx: https://osmnx.readthedocs.io/en/stable/user-reference.html#osmnx.graph.graph_from_address

3 Instalacja, konfiguracja oraz wykonanie projektu

3.1 Instalacja i zbudowanie projektu

Aktualną wersję rozwiązania można znaleźć w otwartym repozytorium na GitHub, pod linkem <https://github.com/JacobPW23/OpenNavigation>.

Aby zapewnić uniwersalność rozwiązania i prostotę obsługi i udostępniania postanowiono skonteneryzować projekt za pomocą technologii Docker. W celu wykorzystania OpenNavigation należy sklonować repozytorium, zbudować obraz oraz uruchomić kontener na podstawie zbudowanego obrazu:

```
git clone https://github.com/JacobPW23/OpenNavigation
cd OpenNavigation
docker compose build
docker compose up -d
```

Należy zwrócić uwagę, iż z powodu instalowania narzędzi Apache, zbudowanie obrazu Docker'a może chwilę zająć.

3.2 Pobór danych (ingestion)

Pobieranie danych jest zautomatyzowane za pomocą skryptów Pythona, które można uruchomić w kontenerze Docker. Poniżej przedstawiono komendy do pobrania danych z poszczególnych źródeł:

Dane APR ZDM

```
docker compose exec opennavigation python \
src/ingestion/zdm_online_traffic_loader.py

docker compose exec opennavigation python \
src/ingestion/zdm_traffic_loader.py

docker compose exec opennavigation spark-submit \
--packages \
org.apache.spark:spark-sql-kafka-0-10_2.12:3.5.1 \
src/processing/traffic_transformations.py

docker compose exec opennavigation python \
src/analysis/zdm_traffic_aggregation.py
```

Wyniki: data/processed/zdm_traffic_by_road.csv.

Raporty prędkości ZDM (PDF)

```
docker compose exec opennavigation python \
src/ingestion/zdm_speed_report_downloader.py

docker compose exec opennavigation python \
src/ingestion/zdm_speed_pdf_parser.py

docker compose exec opennavigation python \
src/analysis/zdm_speed_aggregation.py
```

Wyniki: data/processed/zdm_speed_by_road.csv.

OSM / Overpass

```
docker compose exec opennavigation python \
src/ingestion/overpass_raw_street_loader.py

docker compose exec opennavigation spark-submit \
--packages \
org.apache.spark:spark-sql-kafka-0-10_2.12:3.5.1 \
src/processing/overpass_transformations.py
```

Wyniki: temat *warszawa-processed-edges*.

Pogoda (Open-Meteo)

```
docker compose exec opennavigation python \
src/ingestion/weather_loader.py

docker compose exec opennavigation spark-submit \
--packages \
org.apache.spark:spark-sql-kafka-0-10_2.12:3.5.1 \
src/processing/weather_transformations.py
```

Wyniki: *warszawa-raw-weather*.

3.3 Konfiguracja skryptów analizy

Po udanym postawieniu kontenera, i sprawdzeniu jego działania za pomocą `docker compose ps`, dane mogą zostać pobrane według potoku danych.

Skrypty wykonujące analizę najoptymalniejszej trasy na podstawie danych znajdują się pod następującymi ścieżkami:

- `/app/src/analysis/route_initial_analysis.py`
- `/app/src/analysis/osm_initial_analysis.py`

TODO - opis pozostałych skryptów

W tym raporcie opisane zostanie wykorzystanie pierwszego skryptu. Pozostałe zostaną opisane w ramach raportu końcowego.

Kluczowym punktem dla analizy jest zdefiniowana w tym pliku stała **ROUTES**, w której określone są punkty początkowe i końcowe, dla których ma zostać znaleziona optymalna trasa. Poniżej zamieszczono przykładową konfigurację zmiennej, domyślnie znajdującą się w skrypcie w języku Python:

```
ROUTES = [
    {
        "route_name": "Mokotowska -> Dobra",
        "origin": (52.218662, 21.017080),
        "destination": (52.244974, 21.020670),
    },
]
```

gdzie współrzędne *origin* oraz *destination* są podawane jako (*latitude*, *longitude*).

Aby uruchomić analizę tras, należy wykonać plik analizy tras po wprowadzeniu swojej konfiguracji. Komenda:

```
docker compose exec opennavigation python \
src/analysis/route_initial_analysis.py
```

3.4 Dane wyjściowe

Wyniki wykonania skryptu znajdują się w katalogu `/app/data/results/route_initial_analysis/`. Dla analizy danych istotne są 3 pliki wynikowe:

1. `summary.md` - podsumowanie wyniku analizy skryptu;
2. `routes_comparison.csv` - plik csv podsumowujący najważniejsze aspekty determinujące proponowane trasy: `distance_km`, `base_time_min`, `adjusted_time_min`, `traffic_impacted_edges`, `speed_impacted_edges`, `zdm_apr_edges`, `zdm_speed_edges`, `osmnx_only_edges`;
3. `route_edges.csv` - szczegóły krawędzi najbardziej optymalnej trasy znalezionej przez algorytm, takie jak `traffic_factor`, `speed_factor`, `traffic_speed_factor`, `measured_avg_speed_kmh`, `cost_source`.

4 Wstępna analiza problemu

4.1 Cel i metodyka

Celem rozdziału jest weryfikacja, czy algorytm znajduje sensowną trasę oraz czy czas przejazdu w minutach jest liczony spójnie. Dodatkowo wyniki porównano z czasami i dystansami z Google Maps dla aktualnego obciążenia ruchu (19:00–19:30), aby ocenić zgodność kierunkową. Analiza opiera się na wynikach generowanych przez `route_initial_analysis.py` i zapisanych w `data/results/route_initial_analysis`.

Przyjęta metodyka:

1. Wybrano trzy pary punktów start–cel (*ROUTES*).
2. Dla każdej pary wyznaczono trzy warianty: najkrótszy dystansowo, najszybszy bazowo (na podstawie *travel_time* z OSMnx) oraz wariant skorygowany (*cost_time_s* z uwzględnieniem danych ZDM i pogody).
3. Dla każdej trasy zsumowano długość oraz czasy przejazdu, uzyskując *distance_km*, *base_time_min* i *adjusted_time_min*.
4. Wygenerowane trasy przepisano do Google Maps i odczytano czas oraz dystans dla okna 19:00–19:30.

4.2 Wyniki wstępne

Najpierw zestawiono wyniki generowane przez program (na podstawie *summary.md*) w tabeli 3.

Tabela 3: Wyniki programu dla trzech tras

Trasa	Wariant	Dystans [km]	Czas bazowy [min]	Czas skoryg. [min]
Mokotowska → Dobra	najkrótsza dystansowo	4.73	5.99	7.09
Mokotowska → Dobra	najszybsza bazowo	4.78	5.80	6.56
Mokotowska → Dobra	skorygowana ruchem i pogodą	4.78	5.80	6.56
Dworzec Centralny → Stadion Narodowy	najkrótsza dystansowo	4.32	5.20	6.90
Dworzec Centralny → Stadion Narodowy	najszybsza bazowo	4.32	5.20	6.90
Dworzec Centralny → Stadion Narodowy	skorygowana ruchem i pogodą	4.97	6.35	6.69
Ochota → Powiśle	najkrótsza dystansowo	6.78	8.32	11.14
Ochota → Powiśle	najszybsza bazowo	6.79	8.20	10.94
Ochota → Powiśle	skorygowana ruchem i pogodą	7.14	8.84	9.48

- Wszystkie przedstawione algorytmy znalazły poprawne trasy, na podstawie ich miar. *Najkrótszy dystansowo* ma najkrótszy dystans, *najszybszy bazowo* ma najkrótszy czas bazowy, a *skorygowany* najkrótszy czas skorygowany.

Wyniki porównawcze przygotowano na podstawie ręcznego przepisania wygenerowanych tras do Google Maps i odczytu czasu oraz dystansu dla aktualnego ruchu w godzinach 19:00–19:30. W tabeli podano wartości w formacie *min / km*.

Tabela 4: Porównanie czasu i dystansu z Google Maps (19:00–19:30)

Trasa	Google [min/km]	Najkrótsza [min/km]	Bazowa [min/km]	Skorygowana [min/km]
Mokotowska → Dobra	19 / 6.5	22 / 4.6	26 / 4.9	26 / 4.9
Dworzec Centralny → Stadion Narodowy	34 / 4.5	34 / 4.5	34 / 4.5	30 / 5.2
Ochota → Powiśle	24 / 8.8	34 / 7.5	30 / 7.0	29 / 7.0

- Dla trasy Mokotowska–Dobra, wyniki czasu z programu są wyższe niż w Google Maps, mimo krótszego dystansu. Jest to spowodowane korkami nieprzewidzianymi przez dane o zagęszczeniu trasy. Wariant bazowy i skorygowany nie polepszyły czasu względem najkrótszej trasy, co sugeruje źle dobrane współczynniki bądź niestandardowy ruch dla tej części miasta.
- Dla trasy Dworzec Centralny–Stadion Narodowy wariant najkrótszy i bazowy pokrywają się z czasem z Google Maps. Wariant skorygowany poprawił czas, co sugeruje, że korekta na podstawie danych ZDM i pogody była trafna i poprawiła wynik względem automatycznej trasy Google Maps.
- Dla trasy Ochota–Powiśle algorytm źle wyznaczył trasę, co skutkowało większym dystansem dla najkrótszej trasy niż w wariancie bazowym oraz skorygowanym. Ten błąd jest spowodowany zapisem grafowym OSM, gdzie nie ma oznaczonych zakazów skrętu oraz zamkniętych ulic, które uwzględnia Google Maps. Wariant skorygowany minimalnie poprawił wynik względem bazowego, jednak jest niemal gorszy od wyniku z Google Maps.

4.3 Wnioski

Na podstawie porównań można stwierdzić, że algorytm konsekwentnie wyznacza trzy warianty tras i poprawnie różnicuje je według przyjętych miar (dystans, czas bazowy, czas skorygowany). Korekta kosztu na podstawie danych ZDM i pogody potrafi zmienić wybór trasy i obniżyć czas przejazdu względem wariantu bazowego, co potwierdza sens wykorzystania tych źródeł w celu analizy. Różnice względem Google Maps wskazują na potrzebę dostosowania współczynników oraz uzupełnienia ograniczeń w grafie OSM (np. zakazy skrętu, zamknięcia).

Algorytm skorygowany radzi sobie lepiej niż bazowy oraz najkrótszy, jednak nadal nie obsługuje ruchu w czasie rzeczywistym, co oznacza że nie powinien być używany do omijania aktualnych zagęszczeń i korków na trasach, a raczej do planowania trasy z uwzględnieniem danych historycznych i kontekstowych.

5 Dalsze kierunki badania

W kolejnych etapach powinniśmy skupić się na poprawieniu znajdowania najszybszej trasy oraz poprawie szacowania czasu przejazdu. W tym celu należy rozważyć następujące kierunki:

- **Kalibracja współczynników** – zmiana *traffic_factor* oraz *speed_factor* aby poprawić trafność wyznaczanych tras.
- **Ograniczenia drogowe** – uzupełnienie grafu OSM o zakazy skrętu, zamknięcia i ograniczenia kierunkowe, aby ograniczyć rozbieżności z rzeczywistymi trasami.
- **Dane czasu rzeczywistego** – dodanie często aktualizowanych źródeł (np. zdarzenia drogowe, zagęszczenia ruchu).
- **Walidacja zewnętrzna** – porównanie wyników z rzeczywistymi czasami przejazdu z łatwo dostępnych źródeł (Google Maps nie daje możliwości łatwego zautomatyzowania tworzenia własnych tras)

6 Podsumowanie

W raporcie przedstawiono zbudowaną infrastrukturę projektu oraz zarys potoku przetwarzania danych, który obejmuje pobór danych, buforowanie w Kafka, przetwarzanie w Spark i zapis wyników do struktury katalogów projektu. Opisano kluczowe źródła danych wraz z formatami i przykładowymi wynikami zapytań, co stanowi podstawę do budowy grafu dróg i korekty kosztów przejazdu.

W części analitycznej występuje wstępne porównania wariantów tras dla kilku par punktów, zestawiając wyniki programu z danymi z Google Maps. Analiza pokazuje, że algorytmy poprawnie generują warianty tras pod kątem dystansu i czasu, a korekty na podstawie danych ZDM i pogody potrafią poprawić wynik, choć wciąż występują rozbieżności wynikające z ograniczeń danych oraz uproszczeń w grafie OSM.

Zidentyfikowane ograniczenia wskazują na potrzebę dalszej kalibracji współczynników i uzupełnienia ograniczeń drogowych oraz rozbudowy źródeł danych. Zaproponowane kierunki badań koncentrują się na poprawie trafności wyznaczania tras i zbliżeniu wyników do rzeczywistych czasów przejazdu.