

Raport ze wstępnych badań projektu zespołowego Big Data

Propozycja trasy na podstawie otwartych danych nawigacyjnych dla miasta stołecznego Warszawy

Zespół 12:

Michał Zalewski

Jakub Próchnicki

Jan Machowski

Maciej Kurzydłowski

Jan Domański

Warszawa, 21 maja 2026

Spis treści

1	Wstęp	3
2	Infrastruktura oraz potok przetwarzania danych	3
2.1	Przedstawienie infrastruktury	3
2.2	Potok danych	3
2.2.1	Źródła danych	3
2.2.2	Pobór danych - Kafka	3
2.2.3	Czyszczenie i transformacja danych - Apache Spark, OSMnx	3
2.2.4	Zapis danych	3
3	Instalacja, konfiguracja oraz wykonanie projektu	3
3.1	Instalacja i zbudowanie projektu	3
3.2	Konfiguracja skryptów analizy	3
3.3	Dane wyjściowe	4
4	Wstępna analiza problemu	4
4.1	Wnioski	4
5	Dalsze kierunki badania	4
6	Podsumowanie	4

1 Wstęp

Niniejszy raport jest kontynuacją prac dążących do opracowania modelu propozycji trasy na podstawie otwartych danych nawigacyjnych. Główny cel tego dokumentu to przedstawienie stworzonej w ramach projektu infrastruktury oraz potoku przetwarzania danych. Opisana zostanie również wstępna analiza wyżej wymienionego problemu oraz wnioski wynikające z tej analizy.

W poprzednim dokumencie zawarty został przegląd tematyki, wstępna propozycja źródeł oraz narzędzi wykorzystanych do wykonania projektu, oraz problemów i ograniczeń związanych z wybranymi danymi.

Dla przypomnienia - zaproponowana została reprezentacja miasta w postaci grafu skierowanego, gdzie wierzchołki są przecięciami lub zakończeniami dróg a krawędzie są faktycznymi odcinkami dróg, z odpowiednim zestawem atrybutów - długość, typ drogi, liczba pasów, natężenie ruchu etc. Propozycja ta została wykorzystana do stworzenia wstępnego rozwiązania, które zostanie przedstawione poniżej.

2 Infrastruktura oraz potok przetwarzania danych

2.1 Przedstawienie infrastruktury

2.2 Potok danych

2.2.1 Źródła danych

2.2.2 Pobór danych - Kafka

2.2.3 Czyszczenie i transformacja danych - Apache Spark, OSMnx

2.2.4 Zapis danych

3 Instalacja, konfiguracja oraz wykonanie projektu

3.1 Instalacja i zbudowanie projektu

Aktualną wersję rozwiązania można znaleźć w otwartym repozytorium na GitHub, pod linkem <https://github.com/JacobPW23/OpenNavigation>.

Aby zapewnić uniwersalność rozwiązania i prostotę obsługi i udostępniania postanowiono skonteneryzować projekt za pomocą technologii Docker. W celu wykorzystania OpenNavigation należy sklonować repozytorium, zbudować obraz oraz uruchomić kontener na podstawie zbudowanego obrazu:

```
> git clone https://github.com/JacobPW23/OpenNavigation
> cd OpenNavigation
> docker compose build
> docker compose up -d
```

Należy zwrócić uwagę, iż z powodu instalowania narzędzi Apache, zbudowanie obrazu Docker'a może chwilę zająć.

3.2 Konfiguracja skryptów analizy

Po udanym postawieniu kontenera, i sprawdzeniu jego działania za pomocą `docker compose ps`, dane zostaną pobrane automatycznie według potoku danych.

Skrypty wykonujący analizę najoptymalniejszej trasy na podstawie danych znajduje się pod następującymi ścieżkami:

- `/app/src/analysis/route_initial_analysis.py`
- `/app/src/analysis/osm_initial_analysis.py`

W tym raporcie opisane zostanie wykorzystanie pierwszego skryptu. Pozostałe zostaną opisane w ramach raportu końcowego.

Kluczowym punktem dla analizy jest zdefiniowana w tym pliku stała **ROUTES**, w której określone są punkty początkowe i końcowe, dla których ma zostać znaleziona optymalna trasa. Poniżej zamieszczono przykładową konfigurację zmiennej, domyślnie znajdującą się w skrypcie w języku Python:

```
ROUTES = [  
    {  
        "route_name": "Mokotowska -> Dobra",  
        "origin": (52.218662, 21.017080),  
        "destination": (52.244974, 21.020670),  
    },  
]
```

gdzie współrzędne *origin* oraz *destination* są podawane jako (*latitude*, *longitude*).

Aby uruchomić analizę tras, należy wykonać plik analizy tras po wprowadzeniu swojej konfiguracji. Komenda:

```
> docker compose exec opennavigation python \  
    src/analysis/route_initial_analysis.py
```

3.3 Dane wyjściowe

Wyniki wykonania skryptu znajdują się w katalogu `/app/data/results/route_initial_analysis/`. Dla analizy danych istotne są 3 pliki wynikowe:

1. `summary.md` - podsumowanie wyniku analizy skryptu;
2. `routes_comparison.csv` - plik csv podsumowujący najważniejsze aspekty determinujące proponowane trasy: `distance_km`, `base_time_min`, `adjusted_time_min`, `traffic_impacted_edges`, `speed_impacted_edges`, `zdm_apr_edges`, `zdm_speed_edges`, `osmnx_only_edges`;
3. `route_edges.csv` - szczegóły krawędzi najbardziej optymalnej trasy znalezionej przez algorytm, takie jak `traffic_factor`, `speed_factor`, `traffic_speed_factor`, `measured_avg_speed_kmh`, `cost_source`.

4 Wstępna analiza problemu

4.1 Wnioski

5 Dalsze kierunki badania

6 Podsumowanie